

Krediitkaardi pettuste tuvastamine

TalTechi koolitus „Masinõppe rakendamine tehniliste erialade spetsialistidele”

Sergei Erbin

Andmed

Andmestik on tugevalt tasakaalustamata

284 807

tehingut kokku

Kaks järjestikust päeva, september 2013

492

pettust

0,172% kõigist tehingutest

30

tunnust

Aeg + Summa + 27 kodeeritud tunnust
(V1–V28)

Andmeanalüüs

① Summa

Normaalsed tehingud

Mediaan

Tüüpiline vahemik

~20 €

5 – 80 €

Pettused

Mediaan


Tüüpiline vahemik

~10 €

1 – 100 €

Pettuste summad kattuvad normaalsete tehingutega — summa üksi ei erista klasse.


② Aeg



Erinevus ~6–7×: öösel kuni 1,17% tehingutest on pettused, päeval ainult 0,04%. Aeg on kasulik signaal.

③ Tunnused

Korrelatsioon klassiga




V17 ja V14 on tugevaima korrelatsiooniga — mõlemad mudelid jõuavad samale järeldusele.

Andmete ettevalmistamine

① Tasakaalustamine (SMOTE)

Enne




344 pettust



SMOTE

Pärast



199 020 pettust
(sh sünteetilised)



Normaalne



Pettus (orig.)



Sünteetiline

SMOTE kasvatas pettuste arvu 344-lt 199 020-ni — loob uusi näiteid olemasolevate vahele, ei kopeeri.

② Skaleerimine

Summa

Enne (originaal)

0 – 25 691 €

Pärast skaleerimist

-2.3 ... +8.5

Aeg

Enne (originaal)

0 – 172 792 s

Pärast skaleerimist

-1.7 ... +2.1

StandardScaler rakendatakse ainult treeningandmetel — siis kantakse üle val/test andmetele.

③ Andmete jagamine

70%

70%

Treenimine

~199 000 · Mudel õpib siit

15%

Valideerimine

~43 000 · Läve optimeerimine

15%

Test

~43 000 · Lõplik hindamine

Testandmed on täiesti eraldi — mudel ei näe neid enne lõplikku hindamist.

Mudelite tulemused

Tulemused testandmetel (vaikimisi lävi 0.50)

Mudel	Recall	Precision	F1	AUPRC
Logistic Regression	0.8784	0.0629	0.1173	0.7943
Random Forest	0.8108	0.8696	0.8392	0.8275
LightGBM	0.8243	0.5755	0.6778	0.7969



Parim tulemus



Halvim tulemus

Miks mitte Accuracy? Mudel, mis ennustab KÕIK normaalseks, saab 99,83% täpsuse — aga leiab 0 pettust.

Mõistete selgitus

Recall

Mitu % tegelikest pettustest mudel leiab?

LR: 88% → leiab 88 pettust 100-st

RF: 81% → 19 pettust jääb vahele

Precision

Kui mudel ütleb "pettus" — mitu % on õige?

LR: 6% → 94 vale häiret 100-st

RF: 87% → ainult 13 vale häiret

F1

Kas Precision ja Recall on tasakaalus?

F1 on Precision ja Recall kaalutud keskmine.

LR F1=12% — Precision on liiga madal.

RF F1=84% — mõlemad tasakaalus.

AUPRC

Üldine võimekus kõigi lävede peal korraga.

Juhuslik mudel = 0,002

RF = 0,8275 → 400× parem

Mudeli tulemused — confusion matrix

Vaikimisi lävi 0.50 — testandmed

Logistic Regression	
TN	FP
41 679	969
FN	TP
9	65

Random Forest	
TN	FP
42 639	9
FN	TP
14	60

LightGBM	
TN	FP
42 603	45
FN	TP
13	61

FP — vale häire: normaalne tehing peatati ekslikult. Kliendile tüütu, pangale kulukas.

FN — märkamata pettus: pettus läks läbi. Kõige kallim viga.

Läve optimeerimine

① Numbriline — optimaalne lävi (F1 järgi)

Mudel annab tõenäosuse 0–1. Lävi otsustab: kui tõenäosus $\geq$ lävi $\rightarrow$ "pettus".

Mudel	Lävi	Recall	Precision	F1
Logistic Regression	1.00	74%	81%	77%
Random Forest	0.67	72%	96%	82%
LightGBM	0.97	80%	94%	86%

* LightGBM saab kõrgeima F1=86% optimaalse lävega, kuid AUPRC-It on RF parem (0.8275 vs 0.7969)

② Rahaline — ärintulu (hinnanguline)

Kogukulu = märkamata pettused (FN) $\times$ 122€ + valed häired (FP) $\times$ 10€

Mudel	Lävi 0.50	Optim. lävi	Kokkuhoid
Logistic Regression	10 618€	2 208€	8 410€
Random Forest	2 174€	1 854€	320€
LightGBM	1 892€	1 572€	320€

⚠ Kulud (122€ ja 10€) on näidisväärtused. Täpseks analüüsiks on vaja panga tegelikke andmeid.

Õiget läve ei eksisteeri ilma ärikontekstita — see sõltub sellest, kui kallis on märkamata pettus vs tüütu vale häire.

Häälestamine ja tunnuste tähtsus

① Häälestamise mõju AUPRC-le

Mudel	AUPRC enne	AUPRC pärast	Muutus	Otsus
Logistic Regression	0.7943	0.7946	+0.0003	Vaikimisi param.
LightGBM	0.7969	0.3634	-0.4335	Overfitting!
Random Forest	0.8275	0.8249	-0.0026	Vaikimisi param.

- LR: liiga lihtne — parameetrid ei aita
- LightGBM: overfitting SMOTE andmetele
- RF vaikimisi parim — stabiilne ja üldistuv

② Kõige olulisemad tunnused pettuse tuvastamisel

Random Forest — top 5



LightGBM — top 5



● Mõlemas mudelis

V14 ja V4

on mõlemas
mudelis top 2

Kokkuvõte

Parim mudel: Random Forest · AUPRC 0.8275 · Precision 87% · Recall 81% · Optimaalne lävi 0.67

✓ Kas SMOTE aitas?

Jah — ilma SMOTE-ta mudel nägi ainult 344 pettuse näidet treenimisel.

SMOTE kasvatas pettuse näidete arvu 344 → 199 020. See võimaldas mudelil õppida pettuse mustreid palju paremini.

✓ Kas läve optimeerimine aitas?

Jah — RF vaikumisi lävega 2 174€, optimaalse lävega 1 854€.

Kokkuhoid 320€ (näidisväärtustel põhinev). Läve muutes saab tasakaalustada: tabada rohkem pettusi vs. vähem vale häireid.

✗ Kas häälestamine aitas?

Ei — ükski mudel ei paranenud oluliselt. LightGBM halvenes järsult.

LightGBM AUPRC langes 0.7969 → 0.3634 (overfitting SMOTE andmetele). RF ja LR jäid praktiliselt samaks.

→ Mis on peamine õppetund?

Parim lõpptulemus: RF vaikumisi parameetritega + optimeeritud lävi.

Lihtsus võitis. Häälestamine ei garanteeri alati paremat tulemust, eriti kui treening- ja testandmete jaotus erineb.

Äriline soovitus: Random Forest optimaalse lävega (0.67). Täpseks läve valikuks on vaja panga tegelikke FN/FP kulusid.