

Krediitkaardi pettuste tuvastamine

1. Probleemi kirjeldus

Eesmark: tuvastada pettuslikud krediitkaardi tehingud automaatselt.



Andmestik: 284 807 tehingut (septembrist 2013), millest 492 (0.172%) on pettused.

Andmestik on tugevalt tasakaalustamata - peamine tehniline valjakutse.

Tunnused V1-V28 on anonümitud (PCA), Time ja Amount on originaalsed.

2. Andmestiku graafikud

Joonis 1: Klasside jaotus (vasak) ja korrelatsioon klassiga (parem)



3. Mudelite tulemuste tabel

Mudel	Precision	Recall	F1	AUPRC
Logistic Regression	0.0580	0.9184	0.1092	0.7249
Random Forest *	0.8454	0.8367	0.8410	0.8747
LightGBM	0.4913	0.8673	0.6273	0.8110

* = parim mudel (AUPRC järgi). Precision = mitu % pettushaire test on oiged. Recall = mitu % pettustest tabati. AUPRC = üldine hindamisnaitaja tasakaalustamata andmetel.

Krediitkaardi pettuste tuvastamine

4. Confusion Matrix - Random Forest


Confusion matrix näitab neli tulemust:

Vasak ulanurk (TN): mudel ütles 'normaalne' ja oli oige

Parem ulanurk (FP): mudel ütles 'pettus' aga oli vale (vale haire)

Vasak alanurk (FN): mudel ütles 'normaalne' aga tegelikult oli pettus (vahele jainud!)

Parem alanurk (TP): mudel ütles 'pettus' ja oli oige (tabatud pettus)



Tulemused arvudes:

Oige normaalne (TN): 56,849

Vale haire (FP): 15

Vahele jainud pettus (FN): 16

Tabatud pettus (TP): 82

Recall: $82/98 = 83.7\%$ pettustest tabati

Precision: $82/97 = 84.5\%$ hairetest oli oige

5. Peamised järeldused

Parim mudel: Random Forest (AUPRC=0.8747)

- Tabab 83.7% tegelikest pettustest
- 84.5% pettuseks margitud tehingutest on tegelikult pettused

Olulisemad tunnused: V14, V4, V12, V17 (molemal mudelil yhised)

Suurim valjakutse: klasside tasakaalustamatus (0.172% pettusi)

Lahendus: SMOTE + AUPRC meetrika (mitte tavaline tapsus)

Ariline moju: Random Forest optimaalse lavega saastab ~612 eurot
vorreldus vaikimisi lavega (0.5).