

1. Probleemi kirjeldus


Eesmärk: tuvastada pettuslikud krediitkaardi tehingud automaatselt masinõppe abil.

Andmestik: 284 807 tehingut (september 2013), millest 492 (0.172%) on pettused.

Tunnused V1-V28 on anonüümited PCA komponendid. Time ja Amount on originaalsed.

Peamine väljakutse: andmestik on tugevalt tasakaalustamata -- lahendus: SMOTE + AUPRC meetrika.

2. Andmestiku ülevaade



Joonis 1: Klasside jaotus, tehingusumma jaotus ja top 10 tunnuse korrelatsioon

Klasside jaotus on tugevalt tasakaalustamata -- 284 315 normaalset tehingut vs 492 pettust (0.172%).

Pettuste tehingusummad on sarnase jaotusega normaalsete tehingutega -- summa üksi ei erista klasse.

Tunnused V17, V14, V12 on tugevaima negatiivse korrelatsiooniga -- suured negatiivsed väärtused viitavad pettusele.

3. Mudelite baastulemused

Mudel	Precision	Recall	F1	AUPRC
Logistic Regression	0.0629	0.8784	0.1173	0.7943
Random Forest *	0.8696	0.8108	0.8392	0.8275
LightGBM	0.5755	0.8243	0.6778	0.7969

* = parim AUPRC järgi. AUPRC = üldine hindamisinäitaja tasakaalustamata andmetel.

Precision: kui mudel ütleb 'pettus', siis mitu % juhtumitest on tal õigus. LR 0.06 tähendab, et 94% häiretest on valed.

Recall: mitu % tegelikest pettustest mudel tuvastab. Recall 0.81 -- 19 pettust 100-st jääb vahele.

AUPRC: üldine hindamisinäitaja, lähem 1.0-le parem. Juhuslik ~0.002, RF saab 0.8275 -- kordades parem.

4. Parameetrite häälestamine

RandomizedSearchCV abil otsiti iga mudeli jaoks paremad parameetrid.

Häälestamine ei garanteeri alati paremat tulemust -- vt tulemused allpool.


Mudel	AUPRC enne	AUPRC pärast	Muutus	Kasutada?
Logistic Regression	0.7943	0.7946	+0.0003	Vaikimisi

Krediitkaardi pettuste tuvastamine

LightGBM	0.7969	0.3634	-0.4335	Algne mudel
Random Forest	0.8275	0.8249	-0.0026	Vaikimisi

LightGBM halvenes häälestamisega -- üle sobitumise näide (üle sobitumine SMOTE andmete teel).

5. Confusion Matrix -- kõik mudelid



Joonis 2: Confusion Matrix kõigi mudelite kohta

Kolme mudeli võrdlus:

	Logistic Regression	Random Forest	LightGBM
Õigesti normaalne (TN)	41679	42639	42603
Vale häire (FP)	969	9	45
Märkamata pettus (FN)	9	14	13
Tabatud pettus (TP)	65	60	61

Roheline = soovitud tulemus. Punane = viga (FP = vale häire, FN = märkamata pettus).

6. Äiline läve optimeerimine


Kogukulu = märkamata pettused x 122EUR + valed häired x 10EUR

Optimaalne lävi minimeerib kogukulu valideerimisandmetel.

NB: kulud (122EUR, 10EUR) on hinnangulised näidisväärtused -- indikatiivne analüüs.

Mudel	Vaikimisi lävi 0.50	Optimaalne lävi	Min kulu	Kokkuhoid
Logistic Regression	10 618EUR	0.99	2 208EUR	8 410EUR
Random Forest	2 174EUR	0.21	1 854EUR	320EUR
LightGBM	1 892EUR	0.79	1 572EUR	320EUR

Lävi sõltub optimeerimise eesmärgist: F1-skoor (precision ja recall tasakaalus), äiline kulu (kogukulu minimaalne) või käsitsi PR kõvera järgi. Roheline = madalaim hinnanguline kulu. Õiglast lävi ei eksisteeri ilma ärilise kontekstita.



Joonis 3: Precision-Recall kõver -- mida kõrgem pind kõvera all, seda parem mudel

Juhuslik mudel saaks AUPRC ainult 0.002 -- treenitud mudelid on kordades paremad.

Random Forest (roheline) hoiab kõrgeima pinna all. LightGBM (punane) kukub madalale -- üle sobitumine.

7. Peamised järeldused ja tõlgendus

1. Andmestik -- 284 807 tehingut, 492 pettust (0.172%). Tugevalt tasakaalustamata.

Tõlgendus: juhuslik mudel saaks AUPRC=0.0017 -- treenitud mudelid ületavad seda tulemust kordades.

2. Parim mudel -- Random Forest: AUPRC=0.8275, Recall=0.8108, Precision=0.8696

Tõlgendus: mudel tuvastab 81% pettustest. Iga 100 pettuseks märgitud tehingust on 87% tegelikult pettused.

3. Olulisemad tunnused -- mõlemas mudelis: V14, V4

RF top 5: V14, V4, V10, V12, V17 | LightGBM top 5: V4, V14, V26, V18, V11

Tõlgendus: V14 ja V4 on tugevaimad pettuse indikaatorid -- mõlemad mudelid jõuavad samale järeldusele.

4. Eeltöötlus -- SMOTE lõi sünteetilisi pettuste näiteid väheesindatud klassi õppimiseks.

Vaikimisi 0.5 lävega jääb palju pettusi märkamatuks (kõrge FN). Optimaalse lävega saab tasakaalu ärivajaduse järgi seada.

5. Häälestamine -- RF ei paranenud (-0.0026 AUPRC), LightGBM halvenes tugevalt (üle sobitumine SMOTE andmetele),

LR ei muutunud -- lineaarne mudel on andmestiku keeruliste mustrite jaoks liiga lihtne.

8. Lõppsoovitus

Parim mudel on Random Forest (AUPRC=0.8275): tuvastab 81% pettustest täpsusega 87%.

Kulude analüüs (sektsioon 6) näitab potentsiaalset kokkuhoidu, kuid kulud (122EUR, 10EUR) on hinnangulised -- täpse soovitus saamiseks on vaja panga tegelikke andmeid.

Edasised sammud: (1) hankida tegelikud FN/FP kulud, (2) korrata läve optimeerimist, (3) valida mudel ja lävi tulemuste põhjal, (4) testida reaalses keskkonnas.

Kokkuvõte: Random Forest (AUPRC=0.8275) on tugevaim mudel. Äriline otsus sõltub tegelikest kuludest.

Täielik analüüs (Jupyter notebook): <https://github.com/sergeierbin/creditcard-fraud-detection/blob/master/notebook.ipynb>